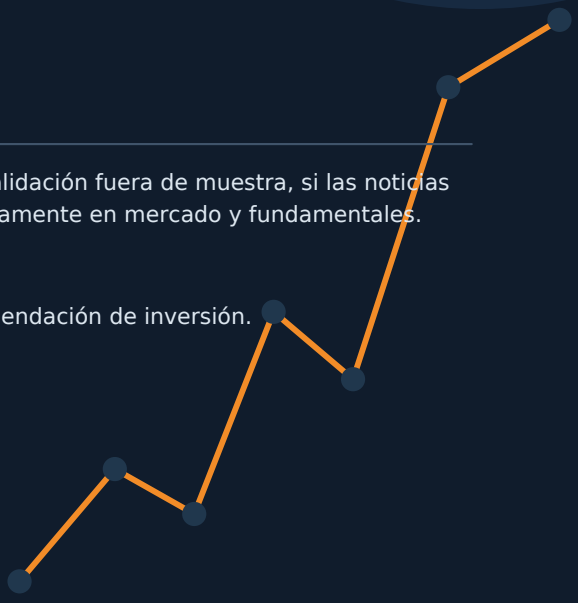
DISEÑO TÉCNICO Y PLAN DE EJECUCIÓN

# WTI NEWS ALPHA

Sistema de investigación cuantitativa para medir y modelar la reacción del petróleo WTI a noticias, eventos y datos fundamentales.



Objetivo: comprobar, mediante datos con marcas temporales fiables y validación fuera de muestra, si las noticias aportan capacidad predictiva incremental frente a modelos basados únicamente en mercado y fundamentales.

Versión 1.1 | 14 de octubre de 2026
Documento de trabajo para investigación individual; no constituye recomendación de inversión.

# Contenido

Mapa del documento. Los capítulos están ordenados para pasar de la definición del problema a los datos, la metodología y la decisión final.


0. Resumen ejecutivo
Qué se va a probar, con qué datos y en qué orden.

1. Pregunta de investigación y alcance
Hipótesis falsables, objetivos y límites del MVP.

2. Proveedores de datos y política de adquisición
Fuentes oficiales, costes y limitaciones clave.

3. Tamaño del dataset y resolución temporal
Frecuencias, volúmenes estimados y almacenamiento.

4. Arquitectura del sistema
Capas de datos, carpetas y reproducibilidad.

5. Modelo de datos y reglas temporales
Tablas, timestamps y prevención de leakage.

6. Pipeline de noticias y construcción de eventos
Ingesta, NLP, ontología y agrupación.

7. Variables predictoras y análisis exploratorio
Features, estudios de eventos y gráficos.

8. Definición de objetivos y etiquetas
Retornos, clasificación, volatilidad y persistencia.

9. Modelos: jerarquía y criterio de selección
Baselines, XGBoost, embeddings y TFT.

10. Validación temporal y simulación económica
Walk-forward, purga, métricas y costes.

11. Criterios de aceptación y puertas de decisión
Go/no-go medible por etapa.

12. Cronograma de implementación
Plan de 16 semanas y entregables.

13. Presupuesto y control de riesgos
Límite de gasto y mitigaciones.

14. Operación, gobierno y checklist final
Reproducibilidad y decisión de salida.

15. Fuentes y documentación oficial
Documentación consultada y enlaces verificables.

16. Proyectos de GitHub y Hugging Face recomendados
Modelos NLP, extracción de noticias, etiquetado, deduplicación y herramientas de experimentación.

# 0. Resumen ejecutivo

WTI News Alpha es un proyecto de investigación, no un sistema de trading listo para desplegar. Busca establecer si los acontecimientos que afectan a la oferta, la demanda y las expectativas del mercado petrolero contienen información útil para predecir la dirección, magnitud y persistencia de los movimientos del futuro NYMEX WTI (símbolo raíz CL).

El proyecto se ejecutará en orden de evidencia: primero se comprobará que los datos históricos y sus tiempos de disponibilidad son suficientes; después se construirá un estudio de eventos; a continuación se medirán modelos sencillos y XGBoost; solo si existe señal robusta se probará un modelo secuencial como Temporal Fusion Transformer (TFT).

> Decisión de diseño central
> La arquitectura debe responder primero a "¿las noticias mejoran el pronóstico frente a mercado + fundamentales?" y solo después a "¿qué modelo es más complejo?". Más parámetros no sustituyen a eventos raros, timestamps fiables ni una prueba fuera de muestra limpia.

| Elemento | Decisión propuesta |
|---|---|
| Activo | Futuros WTI NYMEX CL, con datos por contrato y reglas explícitas de rollover. |
| Objetivo primario | Predicción probabilística de retorno/dirección y volatilidad en horizontes de 15 min, 60 min, 4 h y una sesión; posteriormente 1-3 sesiones para persistencia. |
| Fuentes de noticias | GDELT para descubrimiento/estructura de noticias; registro prospectivo propio desde el inicio. La cobertura histórica, los tiempos y la disponibilidad del texto se auditan antes de asumir que sirve para backtest. |
| Fundamentales | EIA para datos petroleros; FRED/ALFRED para series macro; CFTC COT para posicionamiento; NOAA para eventos meteorológicos. |
| Modelo principal inicial | XGBoost sobre variables tabulares de mercado + fundamentales + eventos; regresión logística/lineal como control interpretable. |
| Modelo avanzado | TFT como experimento posterior y solo con secuencias sincronizadas y suficiente diversidad de episodios. |
| Herramientas | Python, pandas o Polars, DuckDB, Parquet, scikit-learn, XGBoost, matplotlib; Git para versiones y pruebas. |
| Validación | Walk-forward cronológico con purga/embargo de horizontes solapados, embargo temporal cuando proceda y simulación neta de costes. |
| Presupuesto objetivo | Software libre y fuentes públicas en el piloto. No comprometer gasto recurrente hasta validar el dato de precios intradía y la licencia. |

## Principio de falsabilidad

El proyecto debe poder concluir que las noticias no añaden señal predecible, que solo sirven en determinados tipos de evento, o que la ventaja desaparece después de costes. Estos resultados son resultados válidos; no se forzará una estrategia si la evidencia no la sostiene.

# 1. Pregunta de investigación y alcance

## 1.1 Pregunta principal

¿La información de noticias y eventos disponible en el instante de decisión mejora de forma estable y económicamente relevante la predicción del rendimiento o del riesgo de WTI frente a un modelo que solo conoce el comportamiento reciente del mercado y los fundamentales publicados hasta ese instante?

## 1.2 Hipótesis comprobables

- H1 - valor incremental: añadir variables estructuradas de noticias mejora métricas predictivas fuera de muestra frente al mejor modelo market-only o market + fundamentals.
- H2 - heterogeneidad: la capacidad predictiva depende del tipo de evento (suministro, demanda, inventarios, OPEP+, sanciones, clima), novedad, credibilidad y régimen de volatilidad.
- H3 - persistencia: algunas categorías producen movimientos que continúan; otras provocan reacción inmediata y reversión posterior. Dirección inicial y duración deben medirse por separado.
- H4 - utilidad operativa: la mejora estadística se mantiene al aplicar retardos realistas, precios ejecutables, comisiones, spread, slippage y reglas de contrato.

## 1.3 Alcance de la primera versión

Incluido: análisis de eventos, features cuantitativas, modelos de clasificación/regresión/volatilidad, validación temporal y un simulador básico de estrategia. Excluido del MVP: ejecución automática con capital real, redistribución comercial de noticias, sistemas de alta frecuencia, NLP multimodal y arquitectura distribuida.

## 1.4 Dos problemas separados

| Problema | Qué significa | Salida |
|---|---|---|
| A. Reacción inicial | Qué sucede después de la primera disponibilidad fiable de un evento, en minutos u horas. | Retorno, dirección, magnitud, volatilidad, MFE/MAE. |
| B. Persistencia | Si el movimiento continúa, se consolida o revierte horas/sesiones después. | Retorno acumulado por horizonte, retracción desde máximo/mínimo, tiempo de reversión. |

> Regla anti-confusión
> Un modelo puede clasificar correctamente la dirección del próximo intervalo y aun así no ser rentable. La evaluación de predicción y la evaluación de una regla de trading son dos pruebas independientes.

# 2. Proveedores de datos y política de adquisición

El plan de adquisición es mixto: fuentes públicas para noticias, datos fundamentales y contexto; un proveedor de mercado para las barras intradía si no se identifica una alternativa gratuita con cobertura, timestamps y licencia suficientes. Los precios se consideran bloqueante crítico.

| Fuente | Datos y uso | Acceso/coste | Riesgo/condición |
|---|---|---|---|
| GDELT 2.0 DOC / Event / GKG | Noticias globales, metadatos, temas/entidades y detección de eventos. Actualizaciones frecuentes en determinados datasets. | Público; API y descargas según dataset. | No asumir texto completo ni un archivo perfecto de primera disponibilidad. El DOC API se enfoca en una ventana histórica limitada (documentación indica últimos 3 meses por defecto). Auditoría de cobertura obligatoria. [S1] |
| EIA Open Data API v2 | Inventarios de crudo/productos, producción, importaciones/exportaciones, refinerías y balances petroleros. | API gratuita con registro; también hay descargas masivas públicas. [S2] | Usar publicación real: el Weekly Petroleum Status Report normalmente sale miércoles 10:30 ET, con ajustes por festivos. No usar el dato semanal antes de publicarse. [S3] |
| FRED + ALFRED | Contexto macro y series de referencia (por ejemplo, USD, tipos, actividad), según series seleccionadas. | API requiere clave; uso web/API sujeto a sus términos. [S4] | Los valores históricos pueden revisarse. ALFRED/vintages permiten reconstruir lo conocido en determinada fecha, pero no todas las series tienen idéntica disponibilidad vintage. [S5] |
| CFTC COT | Posicionamiento agregado de participantes en futuros/opciones del petróleo. | Informes y ficheros históricos públicos. [S6] | Dato de martes generalmente publicado viernes 15:30 ET; solo entra en features desde su hora real de publicación, con ajuste por festivos y periodos excepcionales. [S6] |
| NOAA NCEI Storm Events | Fenómenos meteorológicos relevantes para la producción, logística o demanda energética en EE. UU. | Base pública y descarga masiva. [S7] | Los reportes pueden publicarse con retraso y no son un feed operativo en tiempo real. Para backtest usar disponibilidad real del reporte, no solo fecha del fenómeno. |
| Databento: CME/NYMEX GLBX.MDP3 | Candidata para históricos de CL: barras OHLCV y, si se necesita, trades/BBO; cliente Python y API. | Pago por uso y planes publicados; el sitio anunciaba crédito de prueba de $125 y Standard de $199/mes en la consulta. [S8] | No comprar hasta simular consulta de volumen/intervalo exacto y comprobar el alcance de licencia. Consultar symbol mapping y regla de rollover. El crédito promocional no se debe asumir garantizado. |
| Registro propio prospectivo | Captura continua desde ahora de publicaciones y hora observada por el sistema; crea evidencia de qué se conocía realmente. | Coste marginal bajo; depende de hosting/almacenamiento si se automatiza. | Es esencial aunque también exista histórico: reduce ambigüedad en disponibilidad futura. Respetar condiciones de cada fuente y derechos de contenido. |

## 2.1 Orden recomendado de adquisición

- Puerta 1 - precios: comprobar disponibilidad histórica de CL por contrato, volumen, continuidad intradía, zona horaria, datos faltantes, expiraciones, método de construcción continuo y precio/licencia.
- Puerta 2 - noticias: medir cuántos artículos relevantes se recuperan por año, proporción de timestamp válido, duplicados, acceso al título/texto y diferencia entre fecha publicada y primera vista.
- Puerta 3 - fundamentales: mapear calendario de publicación y construir registro de cada release. Series diarias/semanales no deben interpolarse como si se conocieran continuamente.
- Puerta 4 - gasto: el piloto puede permanecer gratuito si solo se estudian datos diarios. No declarar viable investigación intradía hasta verificar precio y licencia del proveedor de CL.

# 3. Tamaño del dataset y resolución temporal

## 3.1 Objetivo de datos por fases

| Fase | Precios | Noticias / eventos | Objetivo |
|---|---|---|---|
| Piloto | 6-12 meses si el histórico disponible es limitado; preferible 1-2 años. Barras de 5 min. | Un subconjunto de noticias, con 500-2.000 eventos únicos como meta exploratoria si la cobertura lo permite. | Validar la tubería y medir calidad; no afirmar rentabilidad. |
| MVP de investigación | 1-2 años de 1-5 min si datos/licencia lo permiten; comparar con 5 min. | 10k-50k artículos de partida como orden de magnitud; conservar artículo y evento como entidades distintas. | Estudios de eventos y XGBoost inicial. |
| Expansión | 3-5 años o más, si la estructura de datos es homogénea. | 100k+ artículos puede ser útil; lo determinante es variedad de eventos y timestamps verificados. | Validar robustez por ciclos y episodios históricos. |

Estos rangos son objetivos de planificación, no umbrales científicos universales. El tamaño útil lo determinan la calidad del dato, la cantidad de episodios independientes, la frecuencia de positivos por etiqueta y la longitud del periodo de prueba. 100.000 artículos replicando un único evento no equivalen a 100.000 observaciones independientes.

## 3.2 Orden de magnitud de barras

| Frecuencia | Barras/año aproximadas | Uso |
|---|---|---|
| 1 minuto | ≈ 350.000 | Reacciones rápidas; mayor coste y sensibilidad a calidad/horarios. |
| 5 minutos | ≈ 70.000 | Resolución inicial recomendada para reacción intradía. |
| 15 minutos | ≈ 24.000 | Primera prueba más compacta o análisis de persistencia intradía. |
| 1 hora | ≈ 6.000 | Persistencia y horizontes intradía; insuficiente para reacción inmediata. |

Son aproximaciones redondeadas. Los futuros CL tienen sesiones y una pausa diaria; la cifra real cambia con calendario, gaps y definición de sesión. El contrato estándar representa 1.000 barriles, el símbolo raíz es CL y se cotiza en dólares por barril. [S9]

## 3.3 Almacenamiento y memoria

- Guardar los ficheros originales descargados sin modificarlos. Mantener datos normalizados y features como capas reproducibles separadas.
- Usar Parquet particionado por fuente/año/mes y DuckDB para consultas. Una colección pequeña puede ocupar cientos de MB; texto completo, features NLP y granularidad tick pueden elevar el volumen a varios GB o más.
- 32 GB de RAM y CPU local son suficientes para una primera investigación XGBoost tabular. TFT puede necesitar más tiempo de entrenamiento, pero no requiere GPU como condición de entrada; una GPU acelera algunos experimentos, no arregla datos malos.

# 4. Arquitectura del sistema

La arquitectura separa datos originales, normalización, eventos, variables de modelo, etiquetas, experimentos y resultados. Así se puede corregir una fuente sin alterar inadvertidamente una prueba anterior.

| Capa | Responsabilidad | Artefacto/salida |
|---|---|---|
| 1. Ingesta | Descargar/recibir ficheros, conservar request, response, fecha de ingesta y checksum. | raw/; manifiestos de ingesta; logs de errores. |
| 2. Normalización | Convertir timestamps a UTC, homogeneizar campos, deduplicar con reglas registradas y validar esquema. | silver/ tablas normalizadas. |
| 3. Resolución de eventos | Agrupar artículos sobre el mismo acontecimiento; enlazar entidades, regiones y categoría. | events, event_articles, event_entities. |
| 4. Features point-in-time | Crear snapshots de mercado, fundamentales y noticias que solo usan datos disponibles en t. | features/ con decision_time, data_cutoff_time y feature_version. |
| 5. Etiquetas | Calcular retornos futuros y resultados de eventos de forma independiente de las features. | labels/ con horizonte y reglas versionadas. |
| 6. Experimentos | Entrenar baselines/modelos con splits cronológicos; guardar configuración, semillas y métricas. | runs/, modelos, predicciones OOS y métricas. |
| 7. Evaluación | Analizar valor incremental, calibración, estabilidad y simulación económica. | Informes reproducibles; decisión de continuar/pausar. |

## 4.1 Estructura de carpetas sugerida

```
wti_news_alpha/
config/ # fuentes, sesiones, contratos, parámetros
data/raw/ # respuestas originales, inmutables
data/normalized/ # artículos, precios, fundamentals
data/events/ # eventos, entidades, relaciones
data/features/ # snapshots versionados
data/labels/ # targets por horizonte/versión
notebooks/ # exploración, no producción final
src/ingestion/ # colectores por proveedor
src/normalization/ # timestamps, QA, deduplicación
src/events/ # clasificación y clustering
src/features/ # cálculos point-in-time
src/models/ # baselines, XGBoost, TFT experimental
src/evaluation/ # walk-forward, costes, informes
tests/ # calidad temporal, leakage y schemas
reports/ # gráficos e informes exportados
runs/ # configs, modelos, predicciones, métricas
manifests/ # hashes, fechas, versiones de origen
```

## 4.2 Versionado y reproducibilidad

- Controlar el código con Git; cada experimento debe guardar commit/hash, fuente y periodo del dataset, universo de features, etiqueta, split temporal, hiperparámetros, semilla y librerías.
- No sobrescribir datos crudos. Si el proveedor corrige registros, guardar nueva versión y documentar la fecha de corrección.
- No entrenar desde un notebook de exploración como paso manual irreproducible: el pipeline final debe ejecutarse por comandos y generar artefactos identificables.

# 5. Modelo de datos y reglas temporales

## 5.1 Tablas esenciales

| Tabla | Campos mínimos | Regla principal |
|---|---|---|
| raw_articles | source, url, title, published_at, first_seen_at, ingested_at, language, raw_hash, raw_text si existe, source_payload | Inmutabilidad; no confundir publicación con hora en que el sistema pudo observar el artículo. |
| articles | article_id, canonical_url, title_clean, published_at_utc, first_available_at_utc, source, language, duplicate_group_id | Conservar el original y registrar cómo se canonicaliza/deduplica. |
| events | event_id, event_type, region, entities, event_start_est, first_available_at, novelty, severity, supply_direction, demand_direction, confidence, evidence_ref, extractor_version | Valores no respaldados documentalmente quedan NULL. Un puntaje de modelo no se presenta como impacto físico real. |
| event_articles | event_id, article_id, relation_type, matched_at, match_score | Permite rastrear qué fuentes sustentan el evento. |
| market_bars | ts_start_utc, ts_end_utc, contract_id, OHLCV, trade_count, bid/ask si disponible, bar_complete, source | Cada barra debe mapear a un contrato concreto y a su sesión; no mezclar discontinuidades de rollover con retornos normales. |
| fundamentals | series_id, observation_period, value, release_time, vintage/as_of_time, source, revision_id | Una observación se hace visible únicamente después de la hora de publicación real. |
| feature_snapshots | decision_time, data_cutoff_time, market_features, event_features, fundamental_features, feature_version | La feature store debe permitir reproducir qué se conocía en cada instante de decisión. |
| labels | decision_time, horizon, target_type, target_value, label_version, execution_assumption | Etiquetas separadas de features; el horizonte y precio de entrada/salida quedan versionados. |
| predictions / runs | model_id, run_id, prediction_time, predictions, split_id, model_version, calibration_version | Guardar predicciones OOS en todas las variantes, no solo scores del modelo final. |

## 5.2 Reglas de tiempo obligatorias

- UTC internamente: almacenar todo timestamp con zona horaria; conservar el huso original y convertir releases a hora de Nueva York solo para análisis de sesión/calendario.
- Primera disponibilidad: priorizar first_seen_at verificado por el capturador. Si solo existe published_at, documentar incertidumbre y retrasar conservadoramente el momento accionable.
- Disponibilidad de datos: cada feature tiene un available_at. Para una decisión en t, solo son elegibles los valores donde available_at ≤ data_cutoff_time ≤ t.
- Revisiones: para series revisables, conservar valor conocido en esa fecha o la vintage correspondiente. No descargar la serie final actual y tratarla como si siempre hubiese tenido ese valor. [S5]
- Gaps y contrato: no rellenar automáticamente gaps con precios futuros ni calcular retornos a través de rollovers sin ajuste y regla documentados.

> Prueba automática contra leakage
> Para cada fila de features, comprobar que max(available_at de los componentes) ≤ decision_time. La prueba debe fallar si una noticia, revisión, barra incompleta o dato de publicación posterior contamina el snapshot.

# 6. Pipeline de noticias y construcción de eventos

## 6.1 De artículo a evento económico

| Paso | Método | Control de calidad |
|---|---|---|
| 1. Captura | Guardar título, URL, proveedor, published_at, first_seen_at, idioma, contenido accesible y metadata bruta. | Timestamps válidos; fuente/licencia; URL y hash únicos. |
| 2. Limpieza | Canonicalización de URL, limpieza de HTML, normalización de idioma, deduplicación exacta y aproximada. | No deduplicar usando datos futuros ni colapsar actualizaciones que cambien materialmente el hecho. |
| 3. Relevancia WTI | Filtros por entidades/temas: crudo, OPEP+, productores, exportadores, refinerías, rutas marítimas, sanciones, inventarios, clima. | Auditar falsos positivos y falsos negativos por categoría. |
| 4. Extracción | Clasificar evento y extraer entidades/ubicación, primera mención, estado confirmado/rumor, dirección de posible shock y fuente de evidencia. | Conservar texto/frase de evidencia y versión del extractor. |
| 5. Agrupación | Clustering temporal/semántico para vincular artículos sobre el mismo acontecimiento; conservar updates y fuentes independientes. | Validación humana por muestra; no contar re-publicaciones como shocks separados. |
| 6. Scoring | Calcular novedad relativa, diversidad de fuentes, severidad comunicada y confianza del extractor. | Separar severidad informativa de magnitud física; no inventar barriles/día sin fuente. |
| 7. Snapshot | Agregar conteos/atributos en ventanas móviles previas a cada tiempo de decisión. | Todos los campos deben respetar available_at; conservar evento original para trazabilidad. |

## 6.2 Ontología inicial de eventos

| Categoría | Ejemplos | Hipótesis inicial, no regla causal |
|---|---|---|
| Oferta / interrupción | Ataques a infraestructura, cierre de terminales, fallos de oleoductos, interrupciones productivas. | Posible prima de riesgo alcista si reduce oferta esperada y no está compensada. |
| Geopolítica / sanciones | Sanciones, amenazas, escalada o desescalada, restricciones comerciales. | Depende de si el cambio es nuevo, creíble y altera flujos de crudo. |
| OPEP+ / productores | Cuotas, reuniones, cumplimiento, declaraciones y cambios de política. | Importa la diferencia frente a expectativas, no solo el titular. |
| Inventarios / datos oficiales | EIA: sorpresa de crudo, gasolina, destilados, utilización, importaciones/exportaciones. | La sorpresa respecto al consenso puede ser más informativa que el nivel aislado; el consenso debe estar archivado antes del release. |
| Demanda / macro | Crecimiento, actividad industrial, movilidad, China/EE. UU., datos económicos. | Puede afectar demanda esperada con efectos no lineales según régimen. |
| Clima / logística | Huracanes, cierres portuarios, congelación, disrupción marítima. | Mapear geografía e infraestructura expuesta; NOAA retrospectiva no siempre ofrece disponibilidad inmediata. |
| Mercado financiero | USD, tipos, riesgo amplio, estructura de futuros, flujos correlacionados. | Usar como variables de estado/contexto y no clasificarlos automáticamente como “noticia petrolera”. |

## 6.3 NLP: secuencia de menor a mayor complejidad

- Fase 1: reglas + diccionarios de entidades y categorías para construir una línea base medible.
- Fase 2: modelo de lenguaje o clasificador para estructurar eventos en JSON validado (tipo, entidades, timestamp reportado, estado, evidencia y confianza). Guardar versión del modelo y respuesta original.
- Fase 3: embeddings semánticos como features solo si mejoran de forma incremental frente a metadatos estructurados.
- LLM no debe asignar automáticamente un impacto físico cuantitativo sin respaldo. Las salidas ambiguas se marcan como inciertas; se conservan citas/evidencias y se evalúa una muestra manual.

# 7. Variables predictoras y análisis exploratorio

Las features se calculan en cada decision_time desde ventanas anteriores. Los umbrales, normalizaciones y escalados se ajustan únicamente con entrenamiento. Las siguientes variables son un menú inicial; se eliminarán las que sean redundantes, inestables o no disponibles de forma fiable.

| Grupo | Ejemplos | Tratamiento |
|---|---|---|
| Mercado | Retorno 1/5/15/60 min; 1-3 sesiones; rango; ATR; volatilidad realizada; volumen relativo por hora; momentum; reversión; spread/BBO si hay. | Retardos y ventanas pasadas; normalizar por régimen/hora; marcar datos faltantes y barras incompletas. |
| Noticias | Conteo 15m/1h/4h; número de eventos únicos; novedad; recencia; fuentes distintas; categorías; cambios de intensidad; noticias en conflicto. | Usar solo artículos disponibles; agrupar artículos del mismo evento; evitar conteo de duplicados. |
| Evento | Supply shock score, demand score, estado confirmado/rumor, región, infraestructura, cambio respecto a versión previa, confianza y edad del evento. | Los scores son atributos del extractor, no hechos; validarlos y versionarlos. |
| Fundamentales | Último inventario publicado; cambio semanal; nivel y tendencia de producción; importaciones/exportaciones; utilización de refinerías. | Usar último release conocido, días desde publicación y cambios solo tras release. |
| Macro/posicionamiento | Series macro; USD; tipos; COT neto y cambios; días desde publicación. | ALFRED/vintages cuando aplique; COT solo visible tras publicar. [S5, S6] |
| Calendario | Hora, día, sesión, proximidad a releases programados, vencimiento/roll, festivos, apertura/cierre. | Variables de calendario conocidas de antemano se pueden usar; evitar codificar la sorpresa futura. |
| Interacciones | Evento de oferta × inventarios bajos; sorpresa EIA × tendencia previa; evento geopolítico × alta volatilidad. | Predefinir hipótesis y validar en periodos futuros; controlar el número de combinaciones probadas. |

## 7.1 Análisis exploratorio antes de ML

- Auditoría de cobertura: series temporales de artículos, eventos y barras; gaps, duplicados, rezagos de publicación y proporción de timestamps válidos.
- Distribución del mercado: retornos por horizonte, colas, volatilidad por sesión, gaps y cambios de contrato; establecer benchmarks sin noticias.
- Estudio de eventos: fijar t0 como primera disponibilidad accionable y medir retornos a 5/15/30/60 minutos, cierre de sesión y 1-3 sesiones.
- Resultados del evento: máximo movimiento favorable/adverso (MFE/MAE), volatilidad posterior, tiempo hasta un umbral y tiempo hasta la retracción.
- Segmentación: categoría de evento, novedad, fuente/credibilidad, régimen de volatilidad, hora de sesión, tendencia previa y estado de inventarios.
- Controles: eventos sin noticia detectada, ventanas placebo, noticias de relevancia baja y fechas/hours comparables sin evento.

## 7.2 Qué gráficos y tablas deben producirse

- Histogramas y quantiles de retornos por horizonte; autocorrelación y correlación entre features.
- Event study con medianas y bandas bootstrap agrupadas por evento, no por cada artículo del mismo evento.
- Tasa de acierto y retorno por categoría/deciles de score, siempre con número de episodios e intervalos de incertidumbre.
- Matriz de cobertura por año/categoría y análisis de datos faltantes; tabla de eventos más informativos con fuente rastreable.

# 8. Definición de objetivos y etiquetas

## 8.1 Etiquetas de retorno

Para cada decision_time se calculan objetivos separados por horizonte. Ejemplo conceptual para horizonte h: retorno logarítmico entre un precio de entrada ejecutable después de t y el precio de salida definido por la política de ejecución. No usar el cierre de la misma barra si la señal solo existe al conocer ese cierre.

Horizontes iniciales: 15 min, 60 min, 4 h y fin de sesión; en una segunda fase, 1 y 3 sesiones. Se deben definir como tiempo de mercado válido o tiempo de reloj de forma inequívoca y contemplar cierres, gaps y festivos.

## 8.2 Clasificación bullish / neutral / bearish

Etiquetar como alcista/bajista solo si el retorno excede un umbral relevante; el resto es neutral. Para impedir que el modelo “prediga” oscilaciones menores que el coste, el umbral puede depender de costes ex ante y volatilidad calculada solo con pasado. Un punto de partida para investigación es comparar reglas alternativas, por ejemplo max(coste estimado de ida y vuelta + margen, fracción predefinida de la volatilidad ex ante del horizonte). El umbral se fija usando train y se congela antes de abrir el test.

## 8.3 Objetivos de volatilidad y persistencia

| Target | Definición conceptual | Evaluación |
|---|---|---|
| Retorno continuo | Retorno futuro con ejecución temporal definida. | MAE/RMSE, error por régimen, correlación y retorno neto de una regla fija. |
| Dirección 3 clases | Alcista / neutral / bajista con umbral predefinido. | Balanced accuracy, precision/recall por clase, macro-F1 y matriz de confusión. |
| Volatilidad | Volatilidad realizada futura o rango futuro dentro del horizonte. | MAE/RMSE, calibración de intervalos y calidad por régimen. |
| Persistencia/reversión | Continuación posterior, retracción desde el máximo/mínimo, tiempo al umbral o tiempo de reversión. | Curvas por horizonte, survival/time-to-event si la muestra lo permite, desempeño por categoría. |
| Movimiento operativo | ¿La excursión favorable supera un umbral neto antes de la excursión adversa/stop? | MFE/MAE, proporción objetivo antes de stop y simulación de costes; definir orden temporal si ambos niveles se tocan en una barra. |

## 8.4 Reglas para evitar etiquetas engañosas

- No generar señales fuera de las sesiones previstas ni asumir que se podía ejecutar durante un gap o mercado cerrado.
- Para retorno de trading, usar el primer precio potencialmente ejecutable tras la señal y modelar spread, comisiones, slippage y latencia.
- Etiquetas de horizontes que se solapan comparten información. En validación se purgan ejemplos cuyo intervalo de etiqueta cruza el límite de un split y se aplica embargo cuando corresponda.
- Cuando los datos de una ventana de futuro faltan o atraviesan una discontinuidad de contrato no tratada, la etiqueta se invalida; no se rellena silenciosamente.

# 9. Modelos: jerarquía y criterio de selección

La selección de modelos debe ser un embudo de complejidad creciente. Cada modelo debe competir con el mismo universo temporal, las mismas reglas de disponibilidad y la misma prueba externa.

| ID | Modelo | Inputs | Pregunta que responde |
|---|---|---|---|
| M0 | Naive / base rate | Retorno cero, clase mayoritaria y reglas muy simples. | ¿Hay señal por encima de una referencia trivial? |
| M1 | Regresión lineal/logística regularizada | Variables de mercado. | Benchmark interpretable y calibrable. |
| M2 | XGBoost market-only | Mercado, sesión, calendario y volatilidad. | ¿Cuánto se explica por micro/estructura del mercado sin noticias? |
| M3 | XGBoost + fundamentales | M2 + EIA/FRED/COT/otras series disponibles. | ¿Cuánto añaden los estados fundamentales? |
| M4 | XGBoost + noticias estructuradas | M3 + recencia, categoría, novedad, cantidad y scores de eventos. | Prueba central: valor incremental de noticia. |
| M5 | XGBoost + embeddings | M4 + representación semántica resumida de texto/evento. | ¿Hay señal textual adicional no capturada por la ontología? |
| M6 | TFT / modelo secuencial | Secuencia sincronizada de covariables pasadas + calendario conocido; múltiples horizontes. | ¿Las dependencias secuenciales mejoran de manera robusta a los modelos tabulares? |

## 9.1 Por qué XGBoost primero

- Trabaja con variables tabulares heterogéneas y relaciones no lineales; ofrece una referencia eficaz antes de necesitar una arquitectura secuencial.
- Se puede interpretar parcialmente con importancia de variables, SHAP y pruebas de ablación; estas explicaciones no prueban causalidad.
- Facilita experimentos controlados: mercado versus mercado + fundamentales versus mercado + fundamentales + noticias.
- No exige convertir cada noticia en una secuencia densa; puede aprender de features agregadas por ventanas.

## 9.2 Cuándo probar TFT

TFT está diseñado para pronóstico multihorizonte con covariables estáticas, conocidas por adelantado y observadas históricamente, usando selección de variables y atención temporal. Referencia: Lim et al. (2021), International Journal of Forecasting, DOI 10.1016/j.ijforecast.2021.03.012. [S10] No es un extractor automático de texto de noticias: estas deben transformarse antes en features o representaciones numéricas. Noticias que llegan irregularmente exigen sincronización por barras/snapshots.

- Solo pasar a TFT después de tener pipeline point-in-time estable, baseline fuerte y suficientes episodios cubriendo varios regímenes.
- Empezar con uno o dos horizontes, regularización y early stopping; fijar longitud de lookback con train, no con test.
- Retenerlo únicamente si supera a XGBoost de manera estable en varios cortes OOS y aporta valor económico después de costes. Si no, se descarta.

## 9.3 Hiperparámetros y calibración

Ajustar pocos parámetros con búsqueda acotada en train/validation (profundidad, learning rate, número de árboles, regularización, subsampling y class weights). Para probabilidades, evaluar Brier/log loss y calibrar solo con datos de validación. No seleccionar un modelo por la métrica más favorable entre decenas de intentos sin registrar la multiplicidad de pruebas.

# 10. Validación temporal y simulación económica

## 10.1 Diseño walk-forward

Nunca se barajan aleatoriamente los instantes entre train y test. Se reserva una prueba cronológica final que no interviene en diseño, ingeniería de variables ni selección de umbrales. Durante desarrollo se usan varios ciclos walk-forward con ventanas de entrenamiento expansivas o móviles. La documentación de scikit-learn describe TimeSeriesSplit y su parámetro gap; sin embargo, en este proyecto debe complementarse con purga específica para la duración de cada etiqueta. [S11]

| Etapa | Ejemplo inicial | Regla |
|---|---|---|
| Train | Primer 60-70% de la cronología disponible. | Fit de escaladores, imputadores, selección de features y entrenamiento. |
| Validation | Bloque temporal posterior (por ejemplo 15-20%). | Elección de hiperparámetros, umbrales y calibración; no tocar test final. |
| Test OOS | Último 15-20% o bloque futuro acumulado. | Evaluación sin ajuste posterior. Mantener suficiente número de eventos/periodos. |
| Walk-forward | Repetir en varios cortes, avanzando la fecha de test. | Reportar cada fold y agregado; no depender de un solo régimen de mercado. |

Los porcentajes son una plantilla inicial, no regla rígida. Si la historia es corta o hay muy pocos eventos positivos, aumentar el tamaño de test puede ser más importante que la precisión del tuning. Definir embargo/purga a partir del máximo horizonte de etiqueta y la dependencia temporal.

## 10.2 Controles contra leakage y sobreajuste

- Todo preprocesamiento se ajusta solo con train de cada fold; la selección de variables también se repite dentro del fold.
- Artículos y eventos con versiones/updates deben respetar first_available_at. Un cluster construido con conocimiento futuro puede crear fuga si se atribuye esa información al pasado.
- El periodo de etiqueta que cruza el límite train/test se purga; aplicar embargo temporal si los ejemplos cercanos pueden compartir resultado futuro.
- Los datos revisados se manejan por vintage; releases EIA y COT se activan en su hora verdadera y con calendarios excepcionales.
- Registrar todas las iteraciones, hipótesis, targets, features, parámetros y tests. No elegir retrospectivamente el mejor horizonte/categoría sin penalizar multiplicidad.

## 10.3 Evaluación predictiva y financiera

| Dimensión | Métricas | Por qué |
|---|---|---|
| Dirección | Balanced accuracy, macro-F1, precision/recall por clase. | Evita que una clase mayoritaria oculte fallos. |
| Probabilidades | Brier score, log loss, reliability/calibration curve. | Importa si el resultado se usa para dimensionar riesgo. |
| Regresión | MAE/RMSE y error por volatilidad/categoría. | Cuantifica magnitud del error; no supone rentabilidad. |
| Economía | Retorno neto, Sharpe, max drawdown, hit rate, turnover, exposición, costes, skew y pérdida extrema. | Determina utilidad bajo hipótesis de ejecución concretas. |
| Robustez | Por año, fold, régimen, evento, sesión, volatilidad y lado largo/corto. | Una media positiva puede ocultar que todo proviene de un solo episodio. |

## 10.4 Simulación de trading

La estrategia es una capa posterior al predictor. Se define una regla de actuación con umbral de probabilidad/retorno esperado, posición, stop/time exit y una política de no operar. Los costes deben incluir comisiones, spread, slippage, latencia, rollover, gaps y limitaciones de liquidez. Reportar resultados antes y después de costes y hacer sensibilidad con costes peores que el caso base.

# 11. Criterios de aceptación y puertas de decisión

Cada etapa tiene una puerta de decisión explícita. Estos criterios evitan dedicar meses a un modelo sofisticado cuando la fuente temporal o la hipótesis no soportan el proyecto.

| Puerta | Se acepta si… | Si falla… |
|---|---|---|
| G0 - acceso | Se puede obtener precio CL en el horizonte y frecuencia definidos con licencia/uso compatibles y timestamps verificados; se conoce rollover. | Cambiar a análisis diario/prospectivo o parar el estudio intradía hasta resolver la fuente. |
| G1 - datos | Completitud temporal, proporción de timestamps válidos, duplicación y cobertura por año/categoría documentadas; anomalías críticas explicadas. | Reducir alcance, reparar ingesta o no pasar a modelado. |
| G2 - eventos | Muestra auditada manualmente muestra precisión razonable en categorías clave y trazabilidad a artículos/fuentes. | Simplificar ontología, corregir extracción y volver a evaluar muestra. |
| G3 - EDA | Hay suficiente diversidad de eventos para hacer comparaciones; intervalos de incertidumbre explícitos; no se observan errores temporales críticos. | Limitar preguntas o reunir más datos prospectivos. |
| G4 - baseline | Pipelines de labels/splits reproducibles; baseline y controles placebo funcionan como se espera; no hay leakage conocido. | No entrenar modelos complejos aún. |
| G5 - valor de noticias | M4 supera a M3 fuera de muestra en una métrica primaria predefinida, con estabilidad y sin que un evento aislado domine. | Concluir que no hay evidencia incremental con este dataset o redefinir una hipótesis de forma registrada. |
| G6 - rentabilidad | Regla simple conserva resultado neto y razonable robustez ante costes/slippage mayores; drawdown/exposición dentro de límites predefinidos. | No desplegar; revisar ejecución o declarar solo valor predictivo no monetizable. |
| G7 - TFT | TFT aporta mejora OOS consistente frente a XGBoost y el coste de complejidad es justificable. | Quedarse con modelo tabular más sencillo. |

## 11.1 Cuantificación de los criterios

Los umbrales numéricos de “mejora relevante” no deben inventarse antes de medir la distribución, base rate, costes y error de estimación. En la semana de diseño se elige una métrica primaria por tarea (por ejemplo, Brier score para probabilidades y retorno neto con drawdown para una estrategia), un horizonte principal, un nivel mínimo de actividad y un máximo de riesgo. Los valores se fijan antes de abrir el test.

## 11.2 Registro de experimentos

- Identificador de hipótesis y fecha de pre-registro interno.
- Modelo, versión de datos, periodo, filtros de eventos y decisiones de etiquetado.
- Métrica primaria/secundarias, folds, todos los resultados OOS y resultado de controles placebo.
- Decisión: continuar, ajustar una hipótesis nueva con nuevo versionado o rechazarla.

# 12. Cronograma de implementación

Plan orientativo de 16 semanas para el MVP de investigación trabajando aproximadamente 12-20 horas semanales. Dado que el usuario está consolidando Python y ciencia de datos, conviene presupuestar aprendizaje, depuración y retrabajo. Las fases dependen de la calidad de los históricos y pueden extenderse.

| Semana | Trabajo | Entregable y criterio de salida |
|---|---|---|
| 1 | Definir hipótesis primarias, horizontes, sesiones, instrumento y reglas de ejecución. | Documento de protocolo + lista de datos requerida + definiciones sin ambigüedad. |
| 2 | Auditar proveedores: obtener muestras CL, GDELT, EIA, FRED/ALFRED, COT y NOAA; revisar términos/licencias. | Informe de cobertura/timestamps/coste. Decisión G0: viable intradía o alternativa diaria/prospectiva. |
| 3-4 | Ingesta y archivo raw; normalización UTC; tests de calidad; esquema de tablas. | Pipeline reproducible que vuelve a ejecutar la ingesta sin duplicar ni sobreescribir crudos. |
| 5-6 | Noticias: deduplicación, relevancia WTI, ontología y resolución de eventos; auditoría manual. | Corpus de eventos versionado, con evidencia y métricas de cobertura. |
| 7 | Construir features de mercado/fundamentales y calendario de releases. | Snapshots point-in-time + pruebas automáticas contra leakage. |
| 8 | EDA y estudio de eventos; placebo, estimaciones de incertidumbre y análisis por categorías. | Informe exploratorio; decisión G3 sobre calidad/diversidad de muestra. |
| 9 | Definir/implementar etiquetas y controles para gaps, costes y horizontes solapados. | Labels versionados y unit tests con ejemplos manuales verificables. |
| 10-11 | M0-M4: baselines, regresión/logística y XGBoost con ablaciones de features. | Resultados walk-forward, predicciones OOS y comparación incremental de noticias. |
| 12-13 | Análisis de errores, robustez por régimen/evento, calibración y control de sobreajuste. | Informe de robustez; decisión G5 sobre valor incremental. |
| 14 | Simulador económico simple, costes y análisis de sensibilidad. | Net returns, drawdown, turnover, distribución por fold y escenario de costes. |
| 15 | Replicación independiente / test final sellado y documentación de limitaciones. | Informe final de investigación sin modificar umbrales tras ver test. |
| 16 | Revisión de siguiente paso: continuar, capturar prospectivamente, estudiar TFT o detener. | Decisión documentada con evidencia, gasto real y riesgo residual. |
| 17-20 opcional | Captura prospectiva adicional, robustez ampliada, embeddings o TFT. | Solo si M4/M5 y calidad de datos lo justifican. |

## 12.1 Entregables mínimos del MVP

- Datos raw inmutables, diccionario de datos y scripts de ingesta/versionado.
- Informe de cobertura temporal de noticias y precios; política de disponibilidad y gaps.
- Catálogo de eventos con trazabilidad y muestra auditada manualmente.
- EDA de eventos con intervalos de incertidumbre y placebos.
- Modelos M0-M4 con splits walk-forward, scores OOS y comparación de ablación.
- Simulación económica con costes y limitaciones detallados; conclusión go/no-go y plan de próximos experimentos.

# 13. Presupuesto y control de riesgos

## 13.1 Presupuesto de caja

| Concepto | Plan piloto | Cuándo pagar |
|---|---|---|
| Python, DuckDB, Parquet, scikit-learn, XGBoost, Git | $0 | No debería requerir compra para empezar. |
| EIA, NOAA, CFTC y GDELT | $0 de acceso básico público; comprobar términos/condiciones de uso. | Gasto solo si una necesidad específica exige proveedor/servicio adicional. |
| FRED API | API con registro/clave; sin coste típico de acceso básico. | Cumplir términos de uso y atribución aplicables. |
| Precios intradía CL | No presupuestar como gratis sin probar. Databento ofrece pay-as-you-go; al consultar, su web anunciaba crédito promocional y plan de $199/mes, sujetos a condiciones. [S8] | Primero simular bytes/periodo/schema, revisar licencia CME y confirmar coste exacto antes de descargar. |
| LLM / embeddings | $0 si empieza con reglas y modelo local; coste variable si API. | Solo añadir cuando se compare contra reglas y se mida su valor. No hacer millones de llamadas al comienzo. |
| Almacenamiento/backup | $0 si hay espacio local suficiente; opcional disco de respaldo. | Comprar solo si las copias y datos lo requieren. |

Límite de gasto recomendado
Mantener gasto discrecional inicial en $0-$50 durante el primer mes, salvo que el audit de precios intradía demuestre que una pequeña descarga es el bloqueo que impide decidir. No contratar suscripción recurrente ni descargar tick data masivo antes de estimar coste/valor.

## 13.2 Riesgos críticos y mitigaciones

| Riesgo | Consecuencia | Mitigación |
|---|---|---|
| Histórico de noticias incompleto o no point-in-time | Backtest no reproducible o sesgado por información futura. | Auditoría de primera disponibilidad; capturar noticias prospectivamente; degradar alcance si no hay timestamps fiables. |
| Precio intradía/licencia insuficiente | No se puede medir reacción real ni ejecutar/redistribuir según condiciones. | G0 antes de ML; precio de muestra primero; verificar licencia de datos de intercambio y política de uso. |
| Eventos raros y etiquetas desbalanceadas | Sobreajuste; intervalos amplios; aparente precisión por clase mayoritaria. | Métricas balanceadas, bootstrap por evento, controles placebo, más datos prospectivos y reducción de complejidad. |
| Leakage de timestamps/revisiones | Resultados retrospectivos irreales. | Campos available_at, vintage/as-of, pruebas automáticas y revisión de features de alto impacto. |
| Sobreoptimización | Selección accidental del mejor resultado entre cientos de pruebas. | Pre-registro interno, test final sellado, catálogo de experimentos y pruebas de multiplicidad/robustez. |
| Rollover continuo mal construido | Retornos artificiales, labels erróneas y entradas imposibles. | Precios por contrato, regla de rollover estable y pruebas alrededor de cada cambio; conservar la serie de contrato real. |
| NLP alucina severidad/impacto | Features con cifras no sustentadas o causalidad fabricada. | Evidencia trazable, campos null si no hay fuente, auditoría humana y versión de extractor. |
| Modelo no monetizable | Predicción estadística sin PnL neto. | Separar métrica predictiva y estrategia; simular costes realistas y sensibilidad. |

# 14. Operación, gobierno y checklist final

## 14.1 Política de ejecución reproducible

- Cada ingesta produce log de inicio/fin, fuente, número de registros, rango de timestamps, errores, checksum y versión del script.
- Cada release fundamental se almacena como una publicación inmutable con release_time y, cuando aplique, vintage/revision.
- Cada nuevo modelo produce predicciones fuera de muestra, métricas por fold y artefactos guardados; no solo un número agregado.
- Los resultados de tests exploratorios no se convierten en afirmaciones causales. Para causalidad se requeriría diseño específico que controle confusores y endogeneidad.
- No operar con dinero real hasta contar con pruebas OOS, simulación de costes, protocolo de riesgo, monitorización de drift y plan de contingencia.

## 14.2 Checklist de salida del MVP

☐ ¿Puedo recuperar el dataset exacto que generó cada resultado?

☐ ¿Cada feature solo contiene información disponible en el timestamp de decisión?

☐ ¿Los artículos se enlazan a un evento y se controla la duplicación?

☐ ¿Los valores EIA/CFTC/macro entran solo después de publicarse?

☐ ¿El rollover y las sesiones de CL están documentados y probados?

☐ ¿Las etiquetas usan precios de entrada/salida realizables y controlan solapamientos?

☐ ¿El test final permaneció intacto hasta cerrar diseño y selección?

☐ ¿M4 mejora a M3 de forma consistente y no por uno o dos episodios?

☐ ¿El resultado conserva valor con costes más altos y en varios regímenes?

☐ ¿Se puede explicar qué señales activa el modelo y en qué condiciones falla?

## 14.3 Decisión de proyecto

Al final de las 16 semanas, emitir un veredicto escrito, no ambiguo:

- GO - avanzar: los datos son puntuales y suficientemente completos; las noticias añaden información incremental OOS; los resultados son estables y muestran utilidad después de costes.
- GO limitado - seguir investigando: las noticias mejoran una métrica predictiva o ciertas categorías, pero los resultados económicos son inciertos. Capturar más datos, no desplegar.
- NO-GO intradía: no hay datos históricos point-in-time o costes/licencia compatibles. Reorientar el MVP a análisis diario/prospectivo hasta resolver el acceso.
- NO-GO de señal: las noticias no mejoran de forma robusta el baseline. Documentar el resultado y no escalar a TFT para intentar compensarlo.

# 15. Fuentes y documentación oficial

Consultadas para diseñar las fuentes y restricciones del sistema. El acceso, cobertura, precios, licencias y endpoints pueden cambiar; revisar la documentación y los términos aplicables antes de construir la integración. Fecha de consulta: 14 de octubre de 2026.

[S1] GDELT Project - Data, Event Database y Global Knowledge Graph
Datos y documentación general de datasets; actualización de GDELT 2.0 Event/GKG y cobertura multilingüe.
https://www.gdeltproject.org/data.html

[S1a] GDELT DOC 2.0 API - anuncio y parámetros de ventana temporal
Documenta outputs y ventana de búsqueda temporal del DOC API; no asumir archivo ilimitado de artículos.
https://blog.gdeltproject.org/gdelt-doc-2-0-api-debuts/

[S2] U.S. Energy Information Administration - API developer resources
API pública con registro y documentación de datos energéticos.
https://www.eia.gov/developer/

[S2a] EIA - Open Data API v2 technical documentation
Rutas y ejemplos técnicos del API v2.
https://www.eia.gov/opendata/documentation.php

[S3] EIA - Weekly Petroleum Status Report schedule
Hora estándar y excepciones de publicación del informe semanal.
https://www.eia.gov/petroleum/supply/weekly/schedule.php

[S4] Federal Reserve Bank of St. Louis - FRED API
Documentación de API y series macro.
https://fred.stlouisfed.org/docs/api/fred/

[S5] FRED/ALFRED - Real-Time Periods / vintages
Explica periodos en tiempo real y recuperación de valores como eran conocidos históricamente.
https://fred.stlouisfed.org/docs/api/fred/realtime_period.html

[S6] CFTC - Commitments of Traders and release schedule
Programa de publicación COT; informes normalmente viernes 15:30 ET basados en datos del martes, con excepciones.
https://www.cftc.gov/MarketReports/CommitmentsofTraders/ReleaseSchedule/index.htm

[S7] NOAA NCEI - Storm Events Database
Base de fenómenos meteorológicos y opciones de descarga/bulk data.
https://www.ncei.noaa.gov/access/storm-events-database/

[S8] Databento - Pricing
Precio publicado por uso, planes y productos; confirmar cotización concreta y condiciones vigentes.
https://databento.com/pricing/

[S8a] Databento - continuous futures example
Ejemplo de mapeo de contratos continuos; la elección del contrato activo puede cambiar con volumen.
https://databento.com/docs/examples/symbology/continuous

[S9] CME Group - WTI Crude Oil Futures fact card/specifications
Símbolo CL, tamaño del contrato, cotización y horario de negociación descrito en el documento.
https://www.cmegroup.com/trading/files/WTI-Fact-Card.pdf

[S10] Lim, B., Arik, S. O., Loeff, N. & Pfister, T. (2021). Temporal Fusion Transformers for interpretable multi-horizon time series forecasting. International Journal of Forecasting, 37(4), 1748-1764.
Referencia académica de TFT.
https://doi.org/10.1016/j.ijforecast.2021.03.012

[S11] scikit-learn - TimeSeriesSplit documentation
Validación temporal y argumento gap; complementar con purga/embargo específicos de las etiquetas.
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html

[S12] XGBoost - Python package documentation
Paquete Python para gradient-boosted trees y referencia de API.
https://xgboost.readthedocs.io/en/stable/python/index.html

> Nota sobre las cifras del documento
> Las cifras de barras/año, volúmenes objetivo, semanas y presupuesto son aproximaciones de planificación. Deben actualizarse con una auditoría empírica de cobertura, un quote de precios para el rango y schema elegido, y las necesidades reales del proyecto. No se ha asumido que todo el historial sea gratuito ni que un crédito promocional esté garantizado.

# 16. Proyectos de GitHub y Hugging Face recomendados

Este catálogo es una selección práctica para implementar WTI News Alpha en un equipo local y con presupuesto reducido. No conviene instalar todo a la vez: cada componente debe entrar cuando exista una necesidad concreta, después de probar su precisión, rendimiento, dependencia de recursos y licencia. Los repositorios y model cards se revisaron el 14 de octubre de 2026; el estado de mantenimiento y los términos pueden cambiar.

> Regla de diseño
> Priorizar APIs oficiales, feeds RSS y datos estructurados antes de hacer scraping masivo. Para el MVP, construir primero ingesta fiable, timestamps, deduplicación y revisión manual. Los modelos NLP deben generar features auditables, no decidir por sí solos qué significa una noticia para el precio.

## 16.1 Ingesta, extracción y deduplicación

| Componente | Uso específico en WTI News Alpha | Prioridad y límites |
|---|---|---|
| feedparser<br>BSD-2-Clause | Leer y normalizar RSS/Atom de medios, agencias, reguladores y fuentes de energía. Guardar fecha de publicación, URL, título y fecha de primera observación. | Alta para captura prospectiva. Un feed puede omitir artículos, cambiar metadatos o no ofrecer el texto íntegro. |
| Trafilatura<br>Apache-2.0 desde v1.8.0 | Extraer texto principal y metadatos a partir del HTML de una URL, reduciendo navegación, menús y boilerplate. | Alta como extractor opcional. Primero conservar HTML/raw disponible y registrar fallos; comprobar reglas del sitio y derechos sobre contenido. |
| Scrapy<br>BSD-3-Clause | Framework para crawlers propios cuando hay que recorrer múltiples páginas, paginación, sitemaps o colas de URLs. | Media/baja al inicio. No usarlo para “raspar toda la web”; ejecutar solo sobre fuentes permitidas y con límites de frecuencia. |
| news-please<br>Apache-2.0 | Alternativa integrada para crawling de noticias y extracción de titulares, texto y metadatos; también documenta uso de archivos Common Crawl. | Evaluar en una prueba pequeña. Puede traer más dependencias que una solución feedparser + Trafilatura; no combinarlo de inicio con Scrapy sin necesidad. |
| RapidFuzz<br>MIT | Comparar títulos y URLs normalizadas con similitud de cadenas para detectar republicaciones, titulares casi idénticos y pequeños cambios editoriales. | Alta, barato y sencillo. Umbral debe calibrarse; no unir dos noticias solo porque usan palabras parecidas. |
| datasketch | MinHash/LSH para encontrar texto casi duplicado a escala, útil si crece el archivo de artículos completos. | Opcional. Para el primer corpus puede bastar URL canónica + hash del texto + RapidFuzz. |

Principio importante: “recopilar una URL”, “tener el texto completo” y “saber cuándo el contenido estuvo disponible” son tres hechos distintos. Guardar por separado published_at, first_seen_at y ingested_at; en backtests, usar el primer momento verificable de disponibilidad, con un margen conservador cuando proceda. El texto completo puede no estar accesible por paywalls o por condiciones de uso; el sistema debe funcionar también con título, resumen y metadatos.

## 16.2 Modelos NLP y Hugging Face

| Modelo / proyecto | Qué aporta | Cómo usarlo aquí; riesgos |
|---|---|---|
| Hugging Face Transformers | Biblioteca principal para cargar y ejecutar modelos de texto desde el Hub, realizar clasificación, tokenización y más adelante ajustar un modelo propio. | Base de integración, no predictor financiero. Fijar versiones de paquetes, tokenizer y modelo; guardar revisión exacta y parámetros de inferencia. |
| ProsusAI/finbert (FinBERT)<br>Licencia CC BY-NC-SA 4.0 | Clasifica texto financiero en sentimiento positivo, negativo y neutral. Puede generar probabilidades de sentimiento para titulares y cuerpo del artículo. | Usarlo solo como benchmark de NLP sujeto a revisión de licencia. El model card restringe el uso comercial; no asumir que es apto para un producto/comercialización. Tampoco convierte automáticamente sentimiento en dirección del WTI. |
| VADER Sentiment<br>MIT | Baseline lexicon/reglas rápido y ligero; produce scores de polaridad y magnitud sin una red neuronal grande. | Buen control barato. Fue diseñado principalmente para texto de redes sociales; en noticias financieras, geopolítica y oferta energética su desempeño debe medirse, no darse por supuesto. |
| GLiNER / gliner_small-v2.1<br>Modelo v2.1 indicado como Apache-2.0 | Extracción flexible de entidades usando tipos definidos por el usuario. Puede detectar organizaciones, países, puertos, terminales, oleoductos, productores y actores políticos. | Candidato a segunda fase. Evaluar una muestra etiquetada: la detección no resuelve por sí sola alias, homónimos ni el enlace a una entidad canónica. Probar la latencia en CPU. |
| all-MiniLM-L6-v2 + Sentence Transformers<br>Apache-2.0 para el model card | Crea embeddings semánticos para hallar artículos parecidos, apoyar agrupación de relatos de un mismo evento y explorar temas recurrentes. | Modelo ligero y orientado a inglés. Usar después de URL/hash/similitud de título. No agrupar solo por embedding: dos noticias sobre el mismo tema pueden referirse a eventos distintos. |
| facebook/bart-large-mnli<br>MIT | Clasificación zero-shot: puntúa si un texto encaja en etiquetas redactadas por el investigador, sin entrenar inicialmente una clasificación propia. | Útil para proponer etiquetas candidatas (inventarios, OPEP, sanciones, interrupciones, demanda). Sus puntuaciones no son probabilidades calibradas ni sustituyen revisión humana; ejecutar por lotes y comparar contra reglas. |

> Distinción crítica: sentimiento no equivale a dirección del petróleo
> “Negativo” puede significar caída de demanda (potencialmente bajista) o interrupción de oferta (potencialmente alcista). FinBERT y VADER miden polaridad lingüística; no codifican por defecto mecanismo económico, sorpresa, credibilidad, precio ya descontado ni duración. Conservar sus scores como variables auxiliares y crear una taxonomía explícita de eventos y mecanismos de oferta/demanda.

## 16.3 Etiquetado manual, control de calidad y taxonomía

| Herramienta | Fortaleza principal | Recomendación concreta |
|---|---|---|
| doccano | Anotación de texto y secuencias; clasificación y extracción de entidades; API REST. | Opción ligera para empezar a etiquetar titulares y marcar entidades. Elegir si la tarea central es clasificación/NER. |
| Label Studio<br>Apache-2.0 | Interfaz flexible para distintos tipos de anotación, spans, relaciones y datos variados; soporta pre-etiquetado asistido por modelos. | Alternativa si se necesita definir una interfaz más rica o revisar spans/relaciones. No es necesario instalarlo junto a doccano. |
| Argilla<br>Apache-2.0 | Curación de datasets y revisión iterativa de salidas de modelos por personas; útil para comparar predicciones con etiquetas de referencia. | Más atractivo cuando haya predicciones automáticas que auditar y un flujo continuo de mejora. Usar la línea de versión actual y sus docs. |

### Taxonomía inicial propuesta para el corpus

- Relevancia: directamente relevante para WTI / contexto indirecto / no relevante. Crear negativos difíciles: artículos petroleros sin noticia nueva, opiniones y menciones casuales.
- Familia del evento: inventarios EIA; decisión OPEP+; interrupción de producción; sanciones/geopolítica; conflicto/ataque; clima y huracanes; logística/puertos/oleoductos; demanda y actividad económica; tipos de interés/USD; noticia de empresa; comentario/opinión; otro.
- Mecanismo económico: estrecha oferta; amplía oferta; aumenta demanda; reduce demanda; eleva incertidumbre/riesgo logístico; efecto ambiguo. No forzar una dirección si la evidencia no basta.
- Estado de evidencia: confirmado / atribuido a fuente identificada / preliminar o especulativo / desmentido. Guardar fuente y fragmento de evidencia cuando sea posible.
- Novedad e impacto: nuevo / actualización / repetición; severidad ordinal definida en una guía escrita. Cualquier magnitud cuantitativa, como barriles por día, queda null si no hay fuente verificable.
- Sentimiento del texto: score aparte (VADER/FinBERT/modelo propio), nunca como sustituto de la etiqueta económica.

### Protocolo de etiquetado recomendado

- Crear una guía con definiciones, contraejemplos, reglas para noticias ambiguas y cuándo usar “desconocido/otro”.
- Etiquetar primero un piloto de 200-300 artículos por variedad de categorías; revisar desacuerdos y corregir la guía.
- Ampliar aproximadamente a 500-1.500 artículos como primer corpus de desarrollo, muestreando tanto positivos raros como negativos difíciles. Es un objetivo operativo inicial, no una garantía de suficiencia estadística.
- Mantener un set de evaluación etiquetado por humano y sin usar para ajustar reglas. Si existe una sola persona etiquetando, repetir a ciegas una fracción del conjunto y medir consistencia intra-anotador.
- Separar los artículos vinculados al mismo evento en un mismo grupo temporal para evitar que una noticia duplicada o sus actualizaciones aparezcan en train y test.

## 16.4 Modelos cuantitativos, interpretación y trazabilidad

| Proyecto | Rol y momento de incorporación | Criterio de entrada |
|---|---|---|
| XGBoost docs | Modelo tabular principal para retornos/dirección/volatilidad a partir de features agregadas de mercado, fundamentales, contexto y noticias. | Después de tener labels correctas y baseline. Comparar market-only contra market+fundamentals y luego añadir news en una ablación. |
| SHAP<br>MIT | Explicar las contribuciones de variables en modelos compatibles; inspeccionar cuándo features de noticias afectan la predicción y detectar comportamiento sospechoso. | Útil tras el primer XGBoost. La explicación es asociacional, no causal; comprobar estabilidad en múltiples folds y eventos. |
| PyTorch Forecasting / TFT | Implementación de TFT y otros modelos de secuencias, con series temporales y covariables conocidas/observadas. | Solo después de probar que las noticias añaden señal con XGBoost y que hay datos temporales suficientes. Requiere secuencias alineadas, escalado dentro del train y validación temporal estricta. |

### Matriz mínima de experimentos (misma muestra y mismos folds)

| ID | Entradas | Pregunta que responde |
|---|---|---|
| M0 | Baseline trivial / distribución histórica | ¿El modelo supera no predecir o la tasa base? |
| M1 | Precio y volumen únicamente | ¿Qué puede anticiparse desde el mercado por sí solo? |
| M2 | Mercado + fundamentales + calendario | ¿Añaden valor los datos de inventarios y contexto conocido? |
| M3 | M2 + features estructuradas de noticias | ¿Las noticias aportan valor incremental fuera de muestra? |
| M4 | TFT con historia sincronizada y mismas variables disponibles | ¿La dinámica secuencial mejora establemente a M3? |
| M5 opcional | M3/M4 + embeddings o NLP ajustado con etiquetas propias | ¿La semántica mejora clasificación, persistencia o calibración? |

### Control de experimentos

- Guardar cada corrida con git commit, versiones de datos/features/modelo, fechas de train/validation/test, parámetros, random seed y métricas por fold.
- Durante el MVP basta un registro versionado en CSV/JSON; MLflow puede añadirse si los experimentos crecen. No usar un dashboard de experimentos como sustituto de un protocolo claro.
- Mantener el test final sellado. Embeddings, umbrales, ventanas, taxonomía y hyperparameters se deciden únicamente dentro de entrenamiento/validación.
- Nunca presentar SHAP, atención del TFT o una correlación como prueba de causalidad o evidencia de que la noticia causó el movimiento.

## 16.5 Stack recomendado por fases y revisión de licencias

| Fase | Stack mínimo | Salida y condición para seguir |
|---|---|---|
| A. Ingesta | APIs oficiales + requests; feedparser; Parquet/DuckDB; logs y hashes. | Dataset raw repetible, timestamps separados y auditoría de cobertura. |
| B. Extracción | Trafilatura para extraer HTML permitido; RapidFuzz para similitud; dedupe por URL/hash antes de embeddings. | Métricas de texto extraíble, duplicados y first_seen_at; registro de fuentes no accesibles. |
| C. Etiquetado | Doccano o Label Studio: elegir solo una; Argilla como opción si entra revisión de predicciones. | Guía y dataset piloto auditado; clase de relevancia y taxonomía económica definida. |
| D. NLP baseline | Reglas/diccionarios + VADER; GLiNER small v2.1 para NER como experimento; guardar salida y confianza. | Medir precisión en muestra manual; nada se considera fiable solo por ser salida de un modelo preentrenado. |
| E. Semántica | all-MiniLM-L6-v2 si título/hash no bastan para near-duplicates o agrupación de eventos. | Demostrar mejor precisión de agrupación sin mezclar eventos distintos; mantener cluster auditado. |
| F. Predicción | scikit-learn + XGBoost; SHAP tras primera iteración; TFT vía PyTorch Forecasting solo más tarde. | Ablación M0-M4, walk-forward sin leakage y mejora incremental estable antes de ampliar complejidad. |

### Licencias, datos y condiciones de uso: checklist obligatorio

- FinBERT: la página del modelo ProsusAI declara CC BY-NC-SA 4.0 y advierte que restringe el uso comercial. Para un posible uso comercial, no incorporarlo a producto ni distribuir resultados derivados sin resolver licencia/permiso con asesoría competente. Su repositorio de código y los pesos tienen condiciones que deben comprobarse por separado.
- Modelo y paquete no son la misma licencia: revisar independientemente el código de Transformers, los pesos descargados, tokenizer, datasets de entrenamiento y cualquier modelo fine-tuned. Guardar URL, licencia, revisión/commit y fecha de revisión.
- Scraping: que una librería sea MIT/Apache/BSD no autoriza a copiar contenido periodístico. Revisar robots.txt, condiciones de servicio, derechos de autor, restricciones de API, rate limits y términos de redistribución. Preferir títulos/metadatos y APIs permitidas cuando el texto integral no esté autorizado.
- Datos financieros: verificar por separado la licencia de datos CME/Databento y el uso permitido de históricos derivados. Una biblioteca abierta no elimina obligaciones del proveedor de datos.
- Dependencias: fijar versiones y comprobar vulnerabilidades, mantenimiento, compatibilidad Python y licencia de dependencias transitivas antes de usar en producción.

> Decisión recomendada para la primera iteración
> Instalar solo: feedparser (si usas RSS), Trafilatura (si hay HTML autorizado que extraer), RapidFuzz, Transformers con un baseline elegido, una sola herramienta de etiquetado y XGBoost. Mantener FinBERT como experimento de investigación sujeto a licencia; usar VADER como baseline no costoso; no añadir GLiNER, embeddings ni TFT hasta que la etapa anterior demuestre una necesidad concreta.

Enlaces de referencia principales: FinBERT model card | VADER | GLiNER small v2.1 | MiniLM | doccano | Label Studio | Argilla | Trafilatura | PyTorch Forecasting

Fin del documento. Versión 1.1 - WTI News Alpha.